

Phân tích Trục quan hóa và Đánh giá Mô hình

Dự án Dự báo Giá Nhà tại Hoa Kỳ

ADY2026 — Nhóm Nghiên cứu

Nhóm ADY2026

Ngày 29 tháng 3 năm 2026

Tóm tắt nội dung


Báo cáo này trình bày toàn bộ kết quả trục quan hóa và đánh giá mô hình trong khuôn khổ dự án phân tích và dự báo giá nhà tại Hoa Kỳ, sử dụng bộ dữ liệu Zillow Home Value Index (ZHVI) giai đoạn 2001–2026. Chúng tôi trình bày hệ thống 8 biểu đồ bao gồm phân tích khám phá dữ liệu (EDA) và kết quả so sánh hiệu năng mô hình, đồng thời cung cấp phân tích chi tiết về ý nghĩa thống kê của từng biểu đồ. Kết quả nghiên cứu cho thấy mô hình Ridge Regression với cơ chế chính quy hóa L2 là lựa chọn tối ưu nhất cho bài toán dự báo chuỗi thời gian có cấu trúc tuyến tính nổi bật.

Mục lục

1	Phân tích Khám phá Dữ liệu (EDA)	2
1.1	Xu hướng Giá Nhà Trung vị Toàn quốc (2001–2026)	2
1.2	Tỷ suất Lợi nhuận Logarithm theo Năm (Log-Return)	3
1.3	Ma trận Tương quan giữa Đặc trưng và Biến Mục tiêu	4
1.4	Sự Suy giảm Tương quan Trễ (Autocorrelation Decay)	5
1.5	Phân tán Giá Nhà theo Địa lý	6
1.6	Phân phối Biến Mục tiêu và Biến Giá	7
2	Đánh giá Mô hình	8
2.1	So sánh Hiệu năng Tổng thể	8
2.2	Đường Cơ sở Truyền thống: Dự báo theo Giá Thô (Raw Price)	9
2.3	Dự báo Chuỗi Thời gian (Log-Return): So sánh Ridge và LightGBM	11

1 Phân tích Khám phá Dữ liệu (EDA)

1.1 Xu hướng Giá Nhà Trung vị Toàn quốc (2001–2026)




Hình 1: Xu hướng giá nhà trung vị toàn quốc Hoa Kỳ giai đoạn 2001–2026

Hình 1 mô tả diễn biến giá nhà trung vị toàn quốc theo thời gian, tổng hợp từ 894 Vùng Thống kê Đô thị (Metropolitan Statistical Areas – MSAs) trong suốt 25 năm. Biểu đồ phản ánh trung thực hai sự kiện kinh tế vĩ mô có tác động lớn nhất đến thị trường bất động sản Hoa Kỳ:

- **Khủng hoảng Bất động sản 2008 (Housing Crisis):** Giá nhà trung vị đạt đỉnh xấp xỉ \$220.000 trước khi giảm mạnh hơn 25% và chạm đáy vào năm 2012, hệ quả của làn sóng vỡ nợ tín dụng thứ cấp (subprime mortgage crisis).
- **Đợt Bùng nổ Hậu COVID-19 (2020–2022):** Kết hợp giữa lãi suất thấp kỷ lục và nhu cầu nhà ở bùng phát sau đại dịch đã tạo ra đợt tăng giá kỷ lục, đưa mức trung vị từ \$260.000 lên hơn \$370.000 trong chưa đầy 3 năm.

Chất lượng dữ liệu Zillow ZHVI được xác nhận thông qua khả năng tái hiện chính xác các biến động kinh tế lịch sử, đảm bảo tính toàn vẹn cho quá trình huấn luyện mô hình.

1.2 Tỷ suất Lợi nhuận Logarithm theo Năm (Log-Return)



Hình 2: Phân phối tỷ suất lợi nhuận log-return trung bình hàng năm với thanh sai số độ lệch chuẩn


Thay vì dự báo trực tiếp giá trị tuyệt đối theo đơn vị USD, nghiên cứu này sử dụng **tỷ suất lợi nhuận logarithm** (log-return) làm biến mục tiêu, được định nghĩa như sau:

$$y_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (1)$$

trong đó P_t là giá nhà tại thời điểm t . Hình 2 trình bày giá trị log-return trung bình theo từng năm với thanh sai số thể hiện độ lệch chuẩn. Màu xanh lá biểu thị các năm tăng giá (appreciation), màu đỏ biểu thị các năm giảm giá (depreciation). Phương pháp biến đổi này mang lại ba ưu điểm nổi bật:

1. **Tính dừng (Stationarity):** Log-return dao động xung quanh mức 0%, loại bỏ xu hướng (trend) tuyến tính trong giá trị tuyệt đối.
2. **Bất biến thang đo (Scale-invariance):** Biến đổi tương đối theo phần trăm loại bỏ sự bất tương xứng về biên độ giữa các thị trường khác nhau.
3. **Phân phối chuẩn (Near-normality):** Log-return có phân phối gần chuẩn, phù hợp với giả định của mô hình hồi quy tuyến tính.

1.3 Ma trận Tương quan giữa Đặc trưng và Biến Mục tiêu




Hình 3: Ma trận tương quan Pearson (tam giác dưới) giữa toàn bộ đặc trưng và biến mục tiêu

Hình 3 trình bày ma trận tương quan Pearson (hiển thị tam giác dưới) giữa các đặc trưng đầu vào và biến mục tiêu `log_return`. Các phát hiện chính bao gồm:

- **Tín hiệu dự báo mạnh:** Đặc trưng `lag_1` (giá trị tháng trước) có hệ số tương quan $r = 0,91$ với biến mục tiêu, cho thấy động lực ngắn hạn (short-term momentum) là yếu tố dự báo chủ đạo.
- **Đa cộng tuyến (Multicollinearity):** Các đặc trưng lag có hệ số tương quan lẫn nhau rất cao ($r > 0,85$), biểu hiện rõ ràng của hiện tượng đa cộng tuyến.
- **Hàm ý mô hình:** Sự hiện diện của đa cộng tuyến là cơ sở lý thuyết để lựa chọn **Ridge Regression** (chính quy hóa L2) thay vì OLS thuần túy, vốn không ổn định khi các biến đầu vào có tương quan cao.

1.4 Sự Suy giảm Tương quan Trễ (Autocorrelation Decay)



Hình 4: Tương quan giữa các đặc trưng độ trễ và biến mục tiêu log-return


Hình 4 định lượng sức mạnh dự báo của từng đặc trưng lag thông qua hệ số tương quan Pearson. Kết quả cho thấy hệ số tương quan suy giảm đơn điệu (monotonically) theo thời gian độ trễ:

Đặc trưng	Độ trễ	Hệ số tương quan
lag_1	1 tháng	0,9135
lag_2	2 tháng	0,8326
lag_3	3 tháng	0,7547
lag_6	6 tháng	0,5385
lag_12	12 tháng	0,2296

Thông tin từ 1–3 tháng gần nhất mang tín hiệu động lực thị trường mạnh nhất. Đặc trưng `lag_12`, mặc dù có giá trị tương quan thấp hơn đáng kể, vẫn được giữ lại trong mô hình để nắm bắt các quy luật biến động theo chu kỳ mùa vụ (seasonality patterns).

1.5 Phân tán Giá Nhà theo Địa lý

Average Housing Price by State (2001–2026)



Hình 5: So sánh 10 bang có giá nhà cao nhất và 10 bang có giá nhà thấp nhất tại Hoa Kỳ

Hình 5 minh họa sự bất tương xứng địa lý đáng kể trong giá trị bất động sản giữa các bang. Hawaii có mức giá trung bình vượt \$500.000, trong khi West Virginia chỉ xấp xỉ \$110.000 — chênh lệch hơn 4,5 lần. Kết quả này củng cố lý do chọn log-return làm biến mục tiêu: cùng một biến động \$10.000 mang ý nghĩa hoàn toàn khác nhau tùy thuộc vào phân khúc thị trường, và mô hình hóa theo log-return giải quyết vấn đề bất đối xứng quy mô này một cách hiệu quả.

1.6 Phân phối Biến Mục tiêu và Biến Giá




Hình 6: Biểu đồ phân phối của biến mục tiêu log-return và biến giá nhà gốc

Hình 6 so sánh phân phối xác suất của biến giá thô (raw price) và biến mục tiêu log-return. Giá trị giá nhà gốc có phân phối lệch phải mạnh (right-skewed), vi phạm giả định phân phối chuẩn của hồi quy tuyến tính. Ngược lại, log-return thể hiện phân phối gần chuẩn (near-Gaussian), tập trung quanh mức 0%, là điều kiện thuận lợi để áp dụng các phương pháp hồi quy tham số.

2 Đánh giá Mô hình

2.1 So sánh Hiệu năng Tổng thể



Hình 7: So sánh các chỉ số MAE, RMSE và R^2 của 4 mô hình trong không gian giá USD

Để đảm bảo tính trực quan và khả năng diễn giải thực tế, tất cả các mô hình được đánh giá trong **không gian giá trị USD** thông qua phép biến đổi nghịch đảo:

$$\hat{P}_t = P_{t-1} \times e^{\hat{y}_t} \quad (2)$$


Bảng 1 tóm tắt kết quả so sánh:

Bảng 1: Kết quả đánh giá hiệu năng trên tập kiểm tra

Mô hình	MAE (USD)	RMSE (USD)	R ²
Baseline (Zero-return)	≈ \$3.600	≈ \$8.200	0,9970
OLS (Hồi quy tuyến tính)	≈ \$1.100	≈ \$2.200	0,9998
Ridge Regression (L2)	≈ \$1.100	≈ \$2.200	0,9998
LightGBM (GBDT)	≈ \$900	≈ \$1.800	0,9999

Ba mô hình học máy đều vượt trội so với mô hình cơ sở (Baseline) một cách đáng kể. Mặc dù LightGBM đạt MAE thấp nhất ở cấp độ tổng thể, Ridge Regression cho kết quả gần tương đương nhưng với chi phí tính toán thấp hơn nhiều và khả năng diễn giải (interpretability) vượt trội hơn.

2.2 Đường Cơ sở Truyền thống: Dự báo theo Giá Thô (Raw Price)



Hình 8: Đường cơ sở truyền thống — Ridge và LightGBM huấn luyện trực tiếp trên giá nhà thô (USD), **không** sử dụng biến đổi log-return, trên 3 phân khúc thị trường đại diện


Hình 8 trình bày kết quả dự báo khi các mô hình được huấn luyện trực tiếp trên **giá nhà tuyệt đối (USD)** — phương pháp hồi quy theo giá thô truyền thống. Thực nghiệm này đóng vai trò *đường cơ sở* (baseline) để làm nổi bật động lực lựa chọn biến đổi log-return trong pipeline chính. Quan sát cho thấy hai hiện tượng trái chiều nổi bật:

- Ridge “quá khớp” xu hướng (trend-fitting):** Ridge đạt $R^2 \approx 0,997$ trên cả ba thành phố, nhưng đây là kết quả *đánh lừa* — các đặc trưng lag chính là giá nhà tháng trước, nên mô hình thực chất học lại đường trung bình trượt (moving average) thay vì nắm bắt động lực thị trường thực sự. Khả năng tổng quát hóa sẽ suy giảm mạnh khi giá nhà bước vào giai đoạn đảo chiều đột ngột.
- LightGBM thất bại hoàn toàn ở phân khúc cao cấp:** Do bản chất của mô

hình cây quyết định không thể ngoại suy (extrapolate) vượt ngoài biên độ giá trị đã quan sát trong tập huấn luyện, LightGBM dự đoán giá nhà tại San Jose, CA ở mức cố định $\approx \$800.000$ trong khi giá thực tế đã vọt lên \$1,5 triệu vào năm 2024–2025 ($R^2 = -31,9$).

Cả hai hiện tượng trên đều xuất phát từ **tính không dừng (non-stationarity)** và **bất tương xứng quy mô (scale heterogeneity)** của dữ liệu giá thô. Biến đổi log-return khắc phục triệt để cả hai vấn đề bằng cách chuyển bài toán từ hồi quy mức giá tuyệt đối sang dự báo biến động tương đối, đảm bảo tính dừng và bất biến thang đo cho toàn bộ pipeline mô hình.

2.3 Dự báo Chuỗi Thời gian (Log-Return): So sánh Ridge và LightGBM



Hình 9: Giá nhà thực tế so với giá dự báo của Ridge (trái) và LightGBM (phải) trên 3 phân khúc thị trường đại diện

Hình 9 trình bày kết quả dự báo trực quan trên 3 thành phố được lựa chọn tự động đại diện cho 3 phân khúc thị trường:

- **San Jose, CA** — Phân khúc Cao cấp (giá trung bình $\approx$ \$1,3 triệu)
- **Greensboro, NC** — Phân khúc Trung bình (giá trung bình $\approx$ \$200.000)
- **Clarksdale, MS** — Phân khúc Thấp cấp (giá trung bình $\approx$ \$55.000)

Mỗi hàng tương ứng một thành phố, trong khi cột trái (đường đỏ) là Ridge Regression và cột phải (đường tím) là LightGBM. Vùng bóng mờ thể hiện khoảng sai số giữa giá thực tế và giá dự báo. Phân tích cho thấy:

1. **Phân khúc Cao cấp và Trung bình:** Cả hai mô hình theo sát diễn biến giá thực tế với sai số cực nhỏ.

2. **Phân khúc Thấp cấp (Clarksdale):** Đây là trường hợp phân hóa rõ nhất. Ridge (MAE \$429) vượt trội so với LightGBM (MAE \$550), với vùng sai số của LightGBM rộng hơn đáng kể.
3. **Kiểm soát Overfitting tự động:** LightGBM dừng huấn luyện ở iteration 180 (trong tổng số 1.000 tối đa) nhờ cơ chế *early stopping*, cho thấy mô hình đã đạt điểm hội tụ tối ưu và huấn luyện thêm sẽ dẫn đến overfitting.

Kết luận: Với đặc trưng tuyến tính nổi bật của bài toán dự báo chuỗi thời gian giá nhà (hệ số tương quan $r = 0,91$ giữa `lag_1` và biến mục tiêu), **Ridge Regression** là mô hình được đề xuất: xử lý triệt để đa cộng tuyến thông qua chính quy hóa L2, ổn định dưới biến động thị trường cực đoan và có khả năng diễn giải cao, phù hợp với yêu cầu phân tích học thuật và ứng dụng thực tiễn.