

Phân tích So sánh Hiệu năng Mô hình:

Ảnh hưởng của Biến đổi Log-Return đến Khả năng Dự báo
Giá Bất động sản Chuỗi Thời gian

Phân tích Bổ sung — Dự án ADY2026

Nhóm ADY2026

Ngày 29 tháng 3 năm 2026

Mục lục

1	Giới thiệu và Động lực Nghiên cứu	2
2	Phương pháp Thực nghiệm	3
2.1	Thiết kế Thực nghiệm Có Kiểm soát	3
2.2	Bộ Thuật toán	3
2.3	Tính Toàn vẹn Thời gian (Temporal Integrity)	3
3	Kết quả Thực nghiệm và Phân tích Chi tiết	4
3.1	Tổng quan Số liệu Hiệu năng	4
3.2	Phân tích Biểu đồ So sánh Chỉ số (Hình 1)	5
3.2.1	Quan sát 1 — Hiện tượng “Ảo giác R^2 ”	5
3.2.2	Quan sát 2 — Sự Thất bại Đặc trưng của LightGBM trên Raw Price	6
3.2.3	Quan sát 3 — OLS và Ridge Ổn định Trên Cả Hai Pipeline	7
4	Phân tích Chuỗi Thời gian Trực quan	9
4.1	Baseline: Dự báo Trễ Một Tháng	9
4.2	Raw Price Pipeline: Thành công Giả tạo và Thất bại Đặc trưng	10
4.3	Log-Return Pipeline: Cả Hai Mô hình Tổng quát hóa Tốt	11
5	Lý giải Lý thuyết	13
5.1	Vấn đề Tính không Dừng (Non-Stationarity)	13
5.2	Vấn đề Bất tương xứng Quy mô (Scale Heterogeneity)	13
5.3	Lợi thế Đặc biệt cho Mô hình Phi tuyến (GBDT)	13
6	Kết luận	14

1 Giới thiệu và Động lực Nghiên cứu

Trong lĩnh vực dự báo chuỗi thời gian tài chính và bất động sản, việc lựa chọn biến mục tiêu (target variable) phù hợp là một quyết định kiến trúc có ảnh hưởng sâu sắc đến toàn bộ kết quả mô hình hóa. Hai lựa chọn phổ biến nhất là:

1. **Giá thô tuyệt đối** (Raw Price – P_t): giá trị USD của tài sản tại thời điểm t .
2. **Tỷ suất lợi nhuận logarithm** (Log-Return – r_t):

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) \quad (1)$$

Tài liệu này trình bày một thực nghiệm so sánh có kiểm soát (controlled experiment) nhằm định lượng hóa sự khác biệt về hiệu năng mô hình khi áp dụng hai chiến lược biến đổi mục tiêu trên cùng một bộ dữ liệu Zillow Home Value Index (ZHVI) giai đoạn 2001–2026, với ba câu hỏi nghiên cứu:

- **RQ1:** Biến đổi log-return có mang lại cải thiện có ý nghĩa về MAE và RMSE so với hồi quy giá thô không?
- **RQ2:** Chỉ số R^2 có phải là thước đo đáng tin cậy để đánh giá mô hình dự báo giá bất động sản hay không?
- **RQ3:** Tại sao mô hình phi tuyến (LightGBM) thể hiện hiệu năng tương phản nhau hoàn toàn giữa hai pipeline?

2 Phương pháp Thực nghiệm

2.1 Thiết kế Thực nghiệm Có Kiểm soát

Hai pipeline định dạng dữ liệu hoàn toàn tách biệt được thiết lập song song, sử dụng cùng tập dữ liệu gốc, cùng bộ thuật toán, và cùng giao thức phân chia Train/Test nghiêm ngặt theo trục thời gian.

Bảng 1: Cấu hình hai pipeline thực nghiệm

Thuộc tính	Pipeline A – Log-Return	Pipeline B – Raw Price
Tập huấn luyện	<code>train.csv</code>	<code>train_price.csv</code>
Tập kiểm tra	<code>test.csv</code>	<code>test_price.csv</code>
Biến mục tiêu	$r_t = \ln(P_t/P_{t-1})$	P_t (USD)
Đặc trưng lag	<code>lag_1, ..., lag_12</code>	<code>lag_price_1, ..., lag_price_12</code>
Cắt Train/Test	Cuối năm 2020	Cuối năm 2020
Không gian đánh giá	USD (giải mã ngược)	USD (trực tiếp)

2.2 Bộ Thuật toán

- **Baseline (Zero-Growth):** Mô hình tầm thường dự báo $\hat{P}_t = P_{t-1}$ (giá tháng này bằng giá tháng trước).
- **OLS:** Hồi quy tuyến tính thuần túy. Đầu vào được chuẩn hóa bằng `StandardScaler`.
- **Ridge (L2):** Mở rộng OLS với chính quy hóa L2. Siêu tham số $\alpha \in \{0,01; 0,1; 1,0; 10,0; 100,0\}$ được chọn qua `GridSearchCV` với 5-fold `TimeSeriesSplit`, tối ưu theo `neg_mean_absolute_error`.
- **LightGBM (GBDT):** Tăng cường gradient dựa trên cây quyết định. Huấn luyện với early stopping (độ kiên nhẫn 50 vòng lặp), tách nội bộ 85%/15% làm train/validation. Cấu hình: `n_estimators=1000, learning_rate=0.05, num_leaves=31`.

2.3 Tính Toàn vẹn Thời gian (Temporal Integrity)

Toàn bộ thực nghiệm tuân thủ nghiêm ngặt nguyên tắc phân chia thời gian: mọi chiến lược validation đều sử dụng `TimeSeriesSplit` thay vì K-Fold thông thường, đảm bảo tập validation luôn nằm *sau* tập training trong thứ tự thời gian. Tập Test (2021–2026) bao gồm hai sự kiện thị trường chưa từng xuất hiện trong tập huấn luyện: đợt tăng giá bùng nổ hậu COVID-19 (2021–2022) và giai đoạn điều chỉnh do lãi suất tăng cao (2023–2024).


3 Kết quả Thực nghiệm và Phân tích Chi tiết

3.1 Tổng quan Số liệu Hiệu năng


Bảng 2: Bảng so sánh toàn diện hiệu năng mô hình giữa hai pipeline (đánh giá trong không gian giá USD)

Pipeline	Mô hình	MAE (USD)	RMSE (USD)	R ²	Xếp hạng theo MAE
A – Log-Return	Baseline (Zero-Growth)	\$1.738	\$2.935	0,9997	4
	OLS	\$497	\$810	0,9998	2
	Ridge (L2)	\$497	\$810	0,9998	2
	LightGBM	\$547	\$945	0,9998	3
B – Raw Price	Baseline (Zero-Growth)	\$1.755	\$2.952	0,9997	2
	OLS	\$482	\$776	0,9998	1
	Ridge (L2)	\$484	\$780	0,9998	1
	LightGBM	\$11.246	\$54.033	0,8931	4

3.2 Phân tích Biểu đồ So sánh Chỉ số (Hình 1)



(a) Pipeline A — Log-Return: MAE, RMSE và R^2 của 4 mô hình



(b) Pipeline B — Raw Price: MAE, RMSE và R^2 của 4 mô hình

Hình 1: So sánh hiệu năng toàn diện giữa Pipeline A (Log-Return) và Pipeline B (Raw Price). Các thanh màu xanh biểu thị MAE, thanh màu đỏ biểu thị RMSE, đường màu xanh lá biểu thị R^2 (trục phải).

3.2.1 Quan sát 1 — Hiện tượng “Ảo giác R^2 ”

Quan sát Hình 1a và 1b, điều đầu tiên gây chú ý là đường R^2 màu xanh lá (trục phải) dao động trong khoảng $[0.9997; 1.0000]$ ở hầu hết mọi mô hình trên cả hai pipeline. Đáng

chú ý nhất, mô hình Baseline tầm thường nhất — không sử dụng thuật toán học máy, đơn giản lấy giá tháng trước đặt làm dự báo — cũng đạt $R^2 = 0,9997$.

Hiện tượng này không phải là kết quả của một thuật toán xuất sắc, mà là hệ quả tất yếu của cấu trúc tự tương quan mạnh trong chuỗi thời gian giá bất động sản. Về mặt toán học, R^2 được định nghĩa là:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum_t (P_t - \hat{P}_t)^2}{\sum_t (P_t - \bar{P})^2} \quad (2)$$

Vì phương sai tổng SS_{tot} của giá nhà trải dài trên thang đo hàng trăm nghìn USD là rất lớn, bất kỳ dự báo nào bám sát xu hướng cơ bản — kể cả việc đơn giản “copy” giá tháng trước — cũng sẽ khiến SS_{res} trở nên nhỏ tương đối, đẩy R^2 về sát mức 1. Đây là biểu hiện điển hình của vấn đề *phi dừng* (non-stationarity) trong chuỗi thời gian tài chính.

Kết luận RQ2: Đối với bài toán dự báo giá bất động sản chuỗi thời gian, R^2 **không phải là chỉ số phân biệt** có khả năng so sánh chất lượng mô hình. MAE và RMSE — các thước đo sai số tuyệt đối trong không gian USD — phải được ưu tiên sử dụng làm tiêu chí đánh giá chính.

3.2.2 Quan sát 2 — Sự Thất bại Đặc trưng của LightGBM trên Raw Price

Ở Pipeline B, Hình 1b cho thấy một sự bất thường nổi bật: MAE của LightGBM đạt \$11.246 và RMSE đạt \$54.033 — tệ hơn Baseline lần lượt **6,4 lần** và **18,3 lần**. Đây là hiện tượng phá vỡ hoàn toàn kỳ vọng thông thường, vì LightGBM là thuật toán phức tạp hơn nhiều so với một phép lấy giá trị trễ đơn giản.

Nguyên nhân gốc rễ là giới hạn cố hữu của mô hình cây quyết định: **mô hình cây không thể ngoại suy (extrapolate) vượt ngoài biên độ giá trị đã quan sát trong tập huấn luyện**. Trong tập huấn luyện (2001–2020), giá nhà tại San Jose, CA đạt mức cao nhất khoảng \$1,2 triệu. Khi thị trường vượt qua ngưỡng này trong giai đoạn 2021–2022 (lên đến \$1,5–1,6 triệu), LightGBM không thể phát sinh dự báo vượt quá “trần” đã học. Kết quả: $R^2 = -31,9$ (âm — tệ hơn cả Baseline) và MAE = \$613.622 chỉ riêng cho thành phố này.

Điều này không phải là lỗi cài đặt, mà là đặc tính kiến trúc không thể thay đổi của GBDT khi áp dụng trực tiếp trên không gian giá tuyệt đối.

Ngược lại, trong Pipeline A (Log-Return), LightGBM chỉ cần học cách dự báo *biến động tương đối* trong phạm vi $[-5\%; +5\%]$ — một phạm vi giá trị hoàn toàn đã quan sát trong lịch sử. Nhờ đó, MAE của LightGBM chỉ ở mức \$547 — nằm trong cùng nhóm hiệu năng với Ridge và OLS.

Kết luận RQ3: Sự tương phản hoàn toàn về hiệu năng của LightGBM giữa hai pipeline (MAE \$11.246 vs \$547) bắt nguồn từ giới hạn ngoại suy của GBDT trong không gian giá tuyệt đối. Biến đổi log-return giải quyết triệt để vấn đề này, cải thiện hiệu năng LightGBM hơn **20 lần**.

3.2.3 Quan sát 3 — OLS và Ridge Ổn định Trên Cả Hai Pipeline




Cả OLS và Ridge đều đạt MAE xấp xỉ \$480–500 trên cả hai pipeline (Pipeline A: \$497; Pipeline B: \$482–484). Hai mô hình tuyến tính này không bị ảnh hưởng bởi vấn đề ngoại suy vì hàm dự báo là một siêu phẳng vô biên không có “trần” hay “sàn”. Ridge đặc biệt phù hợp vì đa cộng tuyến cao giữa các đặc trưng lag được xử lý bằng chính quy hóa L2.

Tuy nhiên, hiệu năng tốt của OLS/Ridge trên Raw Price cần được diễn giải thận trọng: mô hình thực chất đang học một hàm *moving average*, không phải một hàm dự báo xu hướng thực sự. Như sẽ trình bày tại Mục 4, điều này dẫn đến hiện tượng “dự báo trễ” khi thị trường đảo chiều đột ngột.

4 Phân tích Chuỗi Thời gian Trực quan

4.1 Baseline: Dự báo Trễ Một Tháng


Baseline (Zero-Growth) Forecast
Actual vs Predicted Housing Prices (2017–2026)



Hình 2 trực quan hóa bản chất của Baseline: đường cam (Baseline Predicted) là đường xanh lá (Test Actual) bị “kéo lùi” đúng một tháng về phía trái. Vùng tô màu (Error Area) thể hiện sai số này.

Do giá bất động sản thay đổi chậm (trung bình 0,3–0,8% mỗi tháng), khoảng cách giữa hai đường rất nhỏ trong điều kiện thị trường bình thường — lý giải tại sao $R^2 \approx 0,97\text{--}0,99$ ngay cả với mô hình tầm thường này. Sai số lớn nhất xảy ra đúng tại các điểm đảo chiều (turning points): khi thị trường bắt đầu tăng nhanh (2021–2022), đường Baseline luôn bị tụt hậu sau thực tế, chứng minh rằng Baseline không có khả năng *dự đoán* mà chỉ có thể *phản ứng muộn*.

4.2 Raw Price Pipeline: Thành công Giả tạo và Thất bại Đặc trưng




Hình 3: Dự báo của Ridge (cột trái) và LightGBM (cột phải) — Pipeline Raw Price. Hàng trên: San Jose CA; Hàng giữa: Bangor ME; Hàng dưới: Clarksdale MS.

Hình 3 tái hiện trực quan hai hiện tượng trái chiều nổi bật trong Pipeline B:

Ridge trên Raw Price (cột trái): Đường dự báo đỏ bám sát đường thực tế xanh lá với $R^2 \approx 0,997$ và $MAE \approx \$342\text{--}\425 tùy thị trường. Tuy nhiên, quan sát kỹ cho thấy đường đỏ luôn có xu hướng lặp lại hành vi tháng trước (smooth, trend-following). Đây là biểu hiện của hiện tượng “moving average fitting”: mô hình học được xu hướng nhưng không học được khả năng thay đổi tốc độ tăng trưởng.

LightGBM trên Raw Price (cột phải): Trường hợp San Jose, CA (hàng trên cùng) là minh họa đặc sắc nhất. Khi giá nhà vượt ngưỡng \$1,2 triệu từ năm 2021 trở đi, LightGBM cố định dự báo ở mức $\approx \$800.000$ trong khi thực tế đã vọt lên \$1,5 triệu vào năm 2024–2025. Kết quả: $R^2 = -31,9$ (âm — thất bại hoàn toàn) và $MAE = \$613.622$. Đây là ví dụ kinh điển về sự cố ngoại suy của GBDT trong không gian giá tuyệt đối.

4.3 Log-Return Pipeline: Cả Hai Mô hình Tổng quát hóa Tốt



Hình 4: Dự báo của Ridge (cột trái) và LightGBM (cột phải) — Pipeline Log-Return. Hàng trên: San Jose CA; Hàng giữa: Greensboro NC; Hàng dưới: Clarksdale MS.

Hình 4 trình bày kết quả của Pipeline A. So sánh trực tiếp với Hình 3, hai sự khác biệt nổi bật:

1. **LightGBM phục hồi hoàn toàn:** Đường tím không còn bị chặn cứng ở mức cũ. Mô hình theo dõi được cả đợt tăng đột biến của San Jose, CA lên mức \$1,5–1,6 triệu, với $\text{MAE} \approx \$547$ — cải thiện hơn **1.000 lần** so với Pipeline B.
2. **Phân khúc Thấp cấp (Clarksdale, MS):** Xuất hiện sự phân hóa rõ ràng giữa hai mô hình tại phân khúc khó dự báo nhất. Ridge ($\text{MAE } \$429$) vượt LightGBM ($\text{MAE } \550) nhờ tính ổn định hơn khi thị trường biến động đảo chiều mạnh (giá giảm từ \$84.000 năm 2022 xuống còn \$45.000 năm 2026).

5 Lý giải Lý thuyết

5.1 Vấn đề Tính không Dừng (Non-Stationarity)

Chuỗi thời gian giá nhà $\{P_t\}$ là *không dừng*: kỳ vọng và phương sai của nó thay đổi theo thời gian, xác nhận bởi kiểm định Augmented Dickey-Fuller với p-value $> 0,05$.

Chuỗi log-return $\{r_t\}$ ngược lại dao động quanh mức 0 với phương sai ổn định, thỏa mãn điều kiện yếu của tính dừng (p-value $\approx 0,001$). Tính dừng là điều kiện cần thiết để các mô hình hồi quy hoạt động đúng giả định thống kê.

5.2 Vấn đề Bất tương xứng Quy mô (Scale Heterogeneity)

Với 894 MSA trong bộ dữ liệu, biên độ giá nhà dao động từ \$45.000 (Clarksdale, MS) đến hơn \$1,6 triệu (San Jose, CA) — hơn 35 lần. Cùng một sai số tuyệt đối \$10.000 mang ý nghĩa hoàn toàn khác nhau tùy thị trường:

- Tại Clarksdale: \$10.000 $\approx 22\%$ giá trị tài sản.
- Tại San Jose: \$10.000 $\approx 0,6\%$ giá trị tài sản.

Log-return chuẩn hóa sai số về cùng đơn vị tương đối (percentage change), loại bỏ bất đối xứng này và cho phép mô hình học một hàm đồng nhất trên toàn bộ phổ thị trường.

5.3 Lợi thế Đặc biệt cho Mô hình Phi tuyến (GBDT)

Lợi ích của log-return đặc biệt lớn đối với GBDT vì trong không gian log-return, biên độ giá trị mục tiêu thu hẹp từ $[0; 1,6 \times 10^6]$ xuống còn $[-0,05; +0,05]$, giúp GBDT học được các quyết định phân chia có ý nghĩa kinh tế thực sự thay vì chỉ ký ức hóa các mức giá tuyệt đối đã quan sát.

6 Kết luận

Thực nghiệm so sánh có kiểm soát này đã cung cấp bằng chứng định lượng và định tính cho ba kết luận chính:

1. **R^2 là chỉ số đánh lừa trong bối cảnh chuỗi thời gian giá bất động sản.** Ngay cả mô hình Baseline tầm thường (dự báo = giá tháng trước) cũng đạt $R^2 \approx 0,9997$. Do đó, R^2 không nên được dùng làm tiêu chí duy nhất. MAE và RMSE phải là thước đo ưu tiên.
2. **Biến đổi log-return giải quyết triệt để vấn đề ngoại suy GBDT.** LightGBM đảo ngược hoàn toàn thứ hạng hiệu năng: từ tệ hơn Baseline 6,4 lần (Raw Price, MAE = \$11.246) sang tương đương OLS/Ridge (Log-Return, MAE = \$547) — cải thiện hơn 20 lần.
3. **Ridge Regression là lựa chọn thực tiễn tối ưu.** Với MAE $\approx$ \$497, tính diễn giải cao, ổn định trên cả hai pipeline, và khả năng xử lý đa cộng tuyến qua chính quy hóa L2, Ridge là mô hình được đề xuất cho bài toán dự báo giá bất động sản chuỗi thời gian.

Hàm ý thực tiễn: Đối với bất kỳ bài toán dự báo chuỗi thời gian tài chính nào có đặc điểm phi dừng và bất đối xứng quy mô, việc biến đổi về không gian tỷ suất lợi nhuận nên được coi là bước tiền xử lý mặc định, đặc biệt khi mục tiêu là sử dụng các mô hình phi tuyến dựa trên cây quyết định.